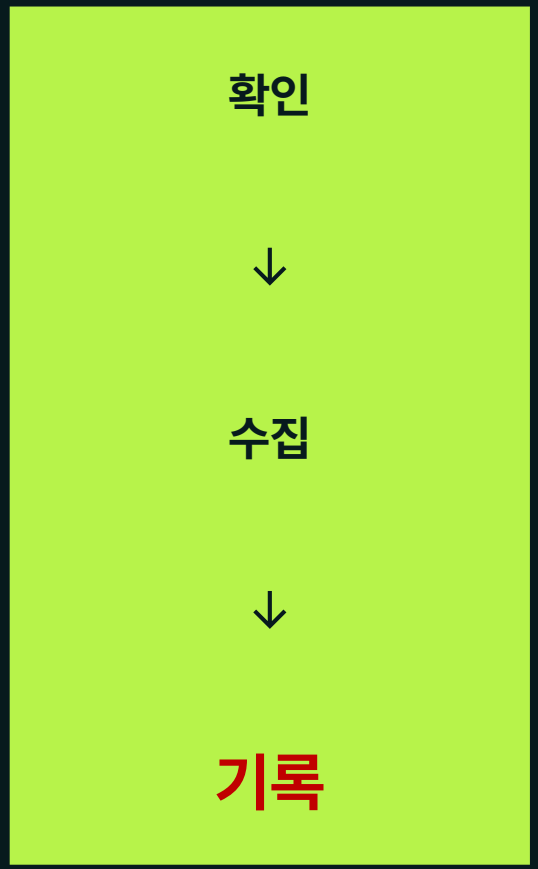
# 웹 크롤링
# 공개 정보 수집

API가 없는 공개 게시판을 규칙을 지키며 표로 모읍니다




금융 실무 AI 과정 · 14주차 1부

# 오늘은 공개 보도자료 게시판을 규칙대로 모아 csv로 만듭니다

산출물 — 보도자료 목록 csv 1개 (번호·등록일·제목·부서·링크·수집일시), robots 확인 기록

| | | |
|---|---|---|
| 01 | 크롤링의 기본 지식 | **화면 · HTML · 표**<br>용어 · 페이지 구조 · 정적과 동적 · 우선순위 |
| 02 | 법과 매너 | **판례 세 건 · 체크리스트**<br>야놀자 · 잡코리아 · hiQ · 수집 전 네 가지 확인 |
| 03 | 세 가지 수집 방법 | **코드 · 브라우저 자동화 · Chrome**<br>BeautifulSoup · Playwright · Chrome |
| 04 | 실습 | **가상 기관 게시판 2쪽**<br>robots 확인 · 2쪽 수집 · 확인표 |

**12주차 API의 짝 — API가 없을 때 쓰는 두 번째 수단입니다**

# 01

# 크롤링의 기본 지식

사람이 보는 화면 뒤에는 프로그램이 읽을 수 있는 HTML이 있다

# 크롤링·스크래핑·API는 같은 '자료 모으기'의 다른 방식입니다

기본 지식 — 실무에서는 크롤링과 스크래핑을 섞어 쓰지만, 뜻을 나누면 위험 판단이 쉬워진다

| 방식 | 뜻 | 예 | 기관의 의도 |
|---|---|---|---|
| **API** | **기관이 열어 준 데이터 창구** | **DART · ECOS** | **가져가라고 만든 것** |
| 크롤링 (crawling) | 링크를 따라 페이지를 돌아다님 | 검색엔진 수집 | robots.txt로 범위 지정 |
| 스크래핑 (scraping) | 페이지에서 원하는 값을 추출 | 게시판 목록 → 표 | 화면용 — 확인 필요 |
| 브라우저 자동화 | 사람처럼 클릭·입력 | Playwright | 가장 신중하게 |

※ 아래로 갈수록 기관이 의도하지 않은 방식이다. 위쪽 수단이 있으면 위쪽을 쓴다.

# 웹 페이지는 태그로 표시된 문서라서, 선택자로 원하는 칸만 꺼낼 수 있습니다

기본 지식 — HTML 태그와 class 이름이 '어디에 무엇이 있는지'를 알려 준다 (실습용 가상 게시판)




선택자(selector) — table.board 안의 tr.item 행마다 td.date · td.title a 를 꺼내고, a.next 를 따라 다음 쪽으로

※ 선택자는 사람이 외우지 않는다. 'HTML 구조를 보고 목록 행의 선택자를 찾아 줘'라고 Claude Code에게 시킨다.

# 내용이 HTML에 바로 있으면 코드로, 클릭해야 나오면 브라우저로 모읍니다

정적(static) 페이지와 동적(dynamic) 페이지 — 페이지 소스 보기(Ctrl+U)에 글자가 보이는지가 판별법

정적 페이지

## 소스에 글자가 있음

- 게시판 목록 · 공지
- requests로 받기
- BeautifulSoup로 추출

**빠르고 서버 부담이 적다**

동적 페이지

## 스크립트가 나중에 채움

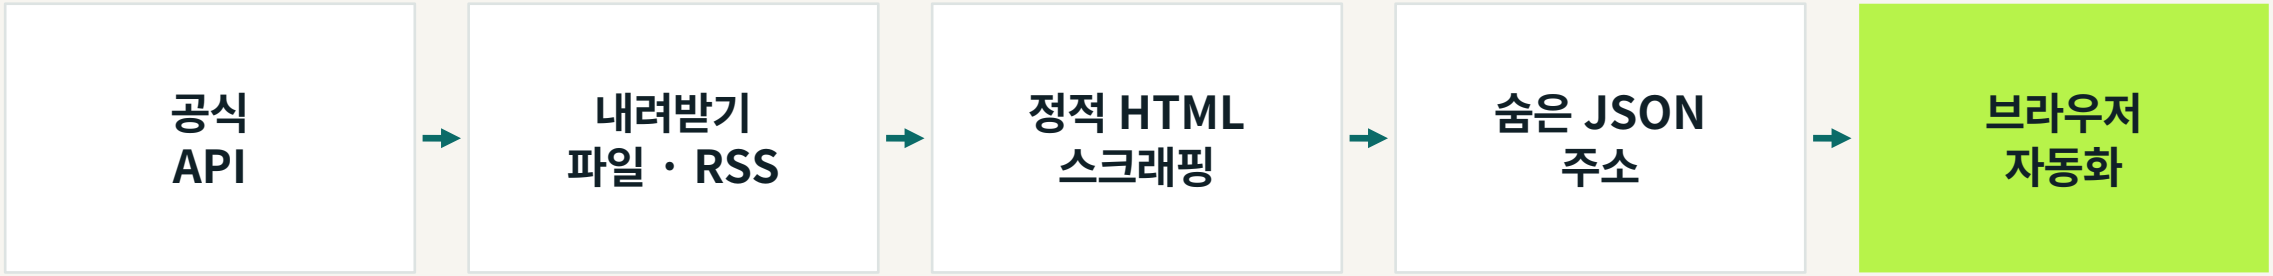
- 검색 결과 · 차트 화면
- 브라우저가 실행해야 보임
- Playwright로 자동화

**느리고 깨지기 쉽다**

※ 동적 페이지 뒤에는 대부분 숨은 데이터 주소(JSON)가 있다. 개발자도구 네트워크 탭에서 먼저 찾아보게 한다.

# 수집 수단은 API부터 시작해 브라우저 자동화를 마지막에 씁니다

위에서 막힐 때만 한 칸 내려간다 — 아래로 갈수록 느리고, 깨지기 쉽고, 법적 판단이 어렵다




## Claude Code에게 맨 먼저 하는 말

**"이 사이트에 API·RSS·내려받기 파일이 있는지 먼저 확인해 줘"**

※ 공공기관 자료는 공공데이터포털·기관 OpenAPI에 이미 있는 경우가 많다. 12주차 키를 다시 쓴다.

# 02

# 법과 매너

기술적으로 가능한 것과 해도 되는 것은 다르다

# 공개 자료라도 수집·이용 방식에 따라 판례의 결론이 갈립니다

사례 세 건 — 형사 무죄와 민사 책임은 별개이고, 약관 위반은 계약 책임으로 남는다

| 사건 | 시기 · 구분 | 결론 |
| --- | --- | --- |
| **잡코리아 v. 사람인** | **2017 · 민사** | **DB 통째 복제 — 배상 책임** |
| **야놀자 v. 여기어때** | **2022 · 대법원 형사** | **망 침입 등 모두 무죄** |
| **hiQ v. LinkedIn** | **2022 · 미국** | **CFAA 위반 아님 · 약관 위반 종결** |

※ 교훈: 남의 DB를 통째로 옮기지 않는다 · 형사 무죄 ≠ 허용 · 약관 동의 시 계약 책임. 업무 판단은 법무·준법 부서가 우선이다.

# 수집 전에 네 가지를 확인하고, 하나라도 걸리면 멈춥니다

Claude Code가 수집 코드를 쓰기 전에 이 네 가지를 먼저 보고하게 한다 (CLAUDE.md 규칙)

1

**robots.txt**

금지 경로 · 간격

2

**이용약관**

자동 수집 금지?

3

**요청 간격**

2초 이상 · 상한

4

**수집 범위**

목록만 수집

**robots.txt는 법이 아니라 사이트 주인의 '의사 표시'입니다.**

**의사를 무시한 수집은 분쟁에서 불리한 사정이 됩니다.**

# 남의 서버를 쓰는 일이므로 사람이 클릭하는 속도보다 빨리 요청하지 않습니다

수집 매너 — 실습 스크립트 crawl_press.py에 모두 들어 있는 장치

하지 않을 것

## 쉬지 않고 대량 요청

- 반복문에 대기 없음
- 전체 게시판 한 번에
- 로그인 뒤 페이지 수집

**접속 차단 · 업무방해 시비**

실습 코드의 장치

## 느리게 · 조금만 · 밝히고

- 요청 간격 2초 이상
- 한 번에 최대 5쪽
- User-Agent에 연락처

**수집일시 열로 기록**

※ 야놀자 사건에서도 '대량 접속으로 서버에 부담을 줬는가'가 쟁점이었다. 매너는 법적 방어선이기도 하다.

# 03

# 세 가지 수집 방법

코드로 읽기 · 브라우저를 자동으로 움직이기 · 내 브라우저에서 Claude가 대신 보기

# 정적 게시판은 requests와 BeautifulSoup로 몇 줄이면 됩니다

방법 1 — 가장 먼저 시도한다. 실습 파일 answers/crawl_press.py가 이 방식이다

**Claude Code에게 이렇게 말합니다**

"이 게시판 첫 쪽의 HTML 구조를 보고
목록 행·날짜·제목·링크의 선택자를 찾아 줘.
그다음 robots.txt를 확인하고,
'다음' 링크를 따라 최대 5쪽까지
2초 간격으로 모아 csv로 저장해 줘."

**Claude Code가 실행하는 명령**

```
pip install beautifulsoup4
(선택자 확인)
 table.board tr.item
 td.date · td.title a
 a.next
python crawl_press.py ...
→ press_YYYYMMDD.csv
```

# 클릭해야 나오는 화면은 Playwright로 브라우저를 대신 움직입니다

방법 2 — 동적 페이지. 9주차 Claude Code 환경에 설치해 쓴다

**Claude Code에게 이렇게 말합니다**

"이 검색 화면은 자바스크립트로 결과를
불러오는 것 같아. 먼저 네트워크 요청에서
숨은 JSON 주소가 있는지 확인하고,
없을 때만 Playwright로 검색어를 넣고
결과 표를 읽어 와 줘."

**Claude Code가 실행하는 명령**

```
(개발자도구 네트워크 분석)
→ JSON 주소 있으면 requests
→ 없으면:
pip install playwright
page.goto(...)
page.fill(...)
page.wait_for_selector(...)
```

**숨은 JSON 주소가 있으면 브라우저를 띄울 필요가 없습니다.**

# 가끔 하는 조회는 코드 대신 Claude in Chrome에게 내 브라우저에서 보게 합니다

방법 3 — 사람이 하던 '열어 보고 옮겨 적기'를 대신. 정기 수집은 코드, 일회성 조회는 Chrome

수집 코드 (방법 1·2)

## 매주 같은 수집

- 예약 작업에 연결
- 결과 형식이 고정
- git으로 관리

**정기 · 대량 · 재현**

Claude in Chrome

## 오늘 한 번 확인

- 내 로그인 상태 그대로
- 화면을 읽고 요약
- 사이트별 권한 승인

**일회성 · 소량 · 사람 옆에서**

※ 로그인한 화면을 Claude가 읽는 것도 '자료를 외부 AI에 보내는 일'이다. 내부 시스템 화면은 회사 규정을 먼저 본다.

# 04

# 실습: 가상 기관 보도자료 수집

sample_site/의 가상 게시판 2쪽 — 실제 서버에 부담 없이 같은 흐름을 연습한다

# 실습은 구조 파악 → robots 확인 → 수집 → 확인 순서로 시킵니다

Week14A_Lab_Files 폴더에서 claude 실행

**Claude Code에게 이렇게 말합니다**

"sample_site/list_p1.html의 게시판 구조를
설명하고, robots.txt를 확인해 결과를 알려 줘.
허용되면 두 쪽 모두 모아 csv로 저장하고,
총 건수·번호 중복 여부·가장 최근 등록일을
보고해 줘."

**기대 결과**

```
robots: 허용 • Crawl-delay 2
1쪽: 10건
2쪽: 10건
총 20건 • 중복 0
최근 등록일 2026-09-30
→ press_YYYYMMDD.csv
```

# 실습이 끝나면 다섯 가지를 확인합니다

확인표 — 실제 사이트에 적용할 때도 같은 표를 쓴다

| 항목 | 확인할 것 | 실습 기대값 |
|---|---|---|
| 수단 | API · RSS · 파일이 없는지 먼저 확인 | 가상 사이트 — 없음 |
| 허용 | robots.txt · 이용약관 결과 보고 | 허용 · 간격 2초 |
| 범위 | 목록만 · 최대 쪽수 상한 | 2쪽 · 20건 |
| 품질 | 번호 중복 · 빈 칸 · 날짜 형식 | 중복 0 · 빈 칸 0 |
| 기록 | 수집일시 열 · 원본 링크 | 모든 행에 존재 |

※ 실제 기관 사이트로 옮길 때는 선택자만 바뀐다. 사이트 개편으로 선택자가 깨지면 0건이 나오므로, 0건을 실패로 기록하게 한다.

# 2부 전에 내 업무의 공개 사이트 하나를 수집 가능성부터 판정합니다

과제는 수집 결과보다 '수단 · 허용 · 범위 판정표'를 본다

과제 1

**판정표**

API · robots · 약관

과제 2

**목록 수집**

수집일시 · 링크 열

2부 예고

**뉴스 × LLM**

근거 구절 · 일치율

**2부에서는 수집한 제목과 요약을 LLM으로 구조화합니다.**

**원문 본문은 저장하지 않고 링크와 근거 구절만 남깁니다.**

API FIRST, SCRAPE LAST.

ASK THE SITE, THEN ASK SLOWLY.

LIST, LINK, AND TIMESTAMP.

---

공개되어 있다는 것과
가져가도 된다는 것은 다릅니다.

14주차 1부 · 웹 크롤링

이어서 — 14주차 2부 뉴스 수집 × LLM 구조화 · 연계: 12주차 공개 API · 15주차 예약 작업